

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное
учреждение высшего образования
**«Южно-Уральский государственный университет
(национальный исследовательский университет)»**
Центр «ВиртУм»

УТВЕРЖДАЮ:
Директор ИЕТН
_____ А.А. Замышляева
_____ 2026 г.

КУРСОВОЙ ПРОЕКТ

по дисциплине «Введение в проектную деятельность»
ЮУрГУ - 09.03.04.2026.306-320.КП

Научный руководитель:
Д-р физ.-мат. наук, доц.
_____ М.Л. Цымблер

Автор работы:
студент группы ЕТ-142
_____ А.А. Дорма

Работа защищена
с оценкой: _____
“ ” _____ 2026 г.

Челябинск, 2026 г.

ОГЛАВЛЕНИЕ

ВВЕДЕНИЕ	3
1. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ТАБЛИЧНЫХ ДАННЫХ	5
1.1. Постановка задачи	5
1.2. Описание выбранного набора данных	7
1.3. Описание результатов первичного анализа	9
1.3.1. Характеристика числовых данных	9
1.3.2. Характеристика категориальных данных	21
1.3.3. Особенности и потенциальные риски использования датасета	24
2. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ДАННЫХ С ВРЕМЕННЫМИ РЯДАМИ	27
2.1. Постановка задачи	27
2.2. Описание выбранного набора данных	29
2.3. Описание результатов первичного анализа	32
2.3.1. Этап 1. Загрузка и первичное знакомство с данными	32
2.3.2. Этап 2. Визуализация исходных данных	33
2.3.3. Этап 3. Статистический анализ.....	34
2.3.4. Этап 4. Анализ пропусков и выбросов.....	37
2.3.5. Этап 5. Анализ диапазонов значений.....	38
2.3.6. Этап 6. Корреляционный анализ	38
2.3.7. Этап 7. Поиск и анализ шумов.....	39
3. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ДАННЫХ С ИЗОБРАЖЕНИЯМИ...	42
3.1. Постановка задачи	42
3.2. Описание выбранного набора данных	44
3.3. Описание результатов первичного анализа	47
3.3.1. Анализ количества и баланса классов.....	48
3.3.2. Примеры типичных изображений с разметкой.....	50
3.3.3. Оценка качества изображений.....	52
3.3.4. Анализ аннотаций (bounding boxes)	52
3.3.5. Оценка качества разметки.....	54
ЗАКЛЮЧЕНИЕ	56
ЛИТЕРАТУРА	57

ВВЕДЕНИЕ

Актуальность

В современном мире технологии искусственного интеллекта (ИИ) и машинного обучения (МО) проникают во все сферы деятельности человека - от медицины и финансов до промышленности и цифровых развлечений. Успех любой ML-модели определяется не только изощренностью архитектуры нейронной сети или выбранного алгоритма, но в первую очередь тем, насколько качественно и репрезентативно подготовлены данные, на которых она обучается. Именно данные являются фундаментом, на котором строится вся аналитика и прогнозирование.

Необходимость первичного анализа данных (Exploratory Data Analysis, EDA) обусловлена прямым влиянием их качества на конечную точность моделей. Многочисленные исследования подтверждают, что игнорирование этапа предварительной обработки и анализа может свести на нет усилия по созданию даже самых сложных алгоритмов. Например, в исследовании с использованием больших языковых моделей для анализа медицинских текстов было экспериментально показано, что при уровне шума (ошибок) в тексте 10% и выше, производительность моделей машинного обучения резко ухудшается, что критично для задач, связанных с риском для жизни пациентов. Схожие результаты были получены при анализе регрессионных моделей: несовпадение процедур очистки обучающих и тестовых данных (mismatched pipelines) может приводить к непредсказуемым изменениям качества предсказаний, что требует от специалиста особой тщательности на этапе первичной обработки признаков. Более того, существует понятие «внутреннего качества датасета» (dataset intrinsic quality), которое не зависит от архитектуры модели: эксперименты показывают, что если набор данных изначально содержит систематические искажения (например, корреляцию целевого признака с шумом), никакое увеличение его размера или сложности

модели не исправит эту ошибку, что делает EDA критически важным инструментом диагностики.

Практикующему специалисту по ИИ приходится сталкиваться с огромным разнообразием типов данных, каждый из которых требует специфических подходов к анализу. Данные могут быть представлены в виде структурированных таблиц (CSV, SQL), где каждая строка - это объект, а столбец - признак. Однако в реальных задачах преобладают неструктурированные данные: текстовая информация (посты в соцсетях, документы), изображения и видео, аудиозаписи, а также временные ряды (показания датчиков, биржевые котировки). Каждая из этих модальностей имеет уникальную природу: для изображений важны гистограммы пикселей и каналы цветов, для текста - частотность токенов и семантические связи, для временных рядов - тренды и сезонность, а для табличных данных - корреляции и распределения. Без инструментов первичного анализа невозможно определить, подходит ли данный массив данных для решения поставленной задачи, и какие методы предобработки необходимо применить.

Таким образом, владение навыками первичного анализа наборов данных различных типов (таблицы, временные ряды, изображения, текст, аудио) является необходимым условием успешной работы специалиста в области искусственного интеллекта. Это позволяет не только сэкономить ресурсы на обучении заведомо несостоятельных моделей, но и выявить скрытые закономерности, которые могут стать конкурентным преимуществом разрабатываемого решения.

1. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ТАБЛИЧНЫХ ДАННЫХ

1.1. Постановка задачи

При работе с табличными данными, хранящимися в реляционных базах данных, одной из ключевых проблем является барьер между пользователем, не владеющим языком SQL, и структурированной информацией. Решение этой проблемы связано с задачей преобразования естественно-языковых запросов пользователя в корректные SQL-запросы (задача Text-to-SQL). Данная задача находится на пересечении обработки естественного языка и реляционных баз данных и является основой для создания интеллектуальных интерфейсов взаимодействия человека с данными.

Тип задачи

Задача относится к классу генеративных задач (sequence-to-sequence) и семантического парсинга. В терминах машинного обучения её можно классифицировать как многоклассовую генерацию последовательности, где SQL-запрос генерируется токен за токеном. Промежуточные подзадачи включают распознавание именованных сущностей для выявления имен таблиц, столбцов и значений, а также классификацию намерений пользователя (определение типа запроса - выборка, агрегация, фильтрация, сортировка).

Входные и выходные данные

На вход модели подается естественно-языковой вопрос пользователя, представленный в виде текстовой строки на русском или английском языке (например, «Покажи всех клиентов, которые сделали заказы на сумму более 10 000 рублей в прошлом месяце»). Дополнительно на вход может подаваться схема базы данных (список таблиц, столбцов, типов данных, связей между таблицами) в качестве контекста. На выходе модели ожидается корректный SQL-запрос, соответствующий смыслу вопроса пользователя и синтаксису конкретной СУБД (например, `SELECT * FROM clients WHERE total_orders > 10000 AND order_date >= '2025-03-01'`).

Предметная область

Задача относится к широкому кругу предметных областей, где данные хранятся в реляционных базах данных, а пользователи не обладают навыками SQL. Применимость охватывает такие сферы, как бизнес-аналитика и корпоративные информационные системы, электронная коммерция и управление отношениями с клиентами, здравоохранение (запросы к базам данных пациентов), образование (анализ успеваемости), государственные информационные системы.

Практическая значимость

Решение задачи Text-to-SQL обладает высокой практической ценностью. Во-первых, оно позволяет не-техническим специалистам (менеджерам, маркетологам, аналитикам бизнеса) получать аналитику из баз данных без необходимости изучать SQL или привлекать разработчиков, что сокращает время получения инсайтов с нескольких дней до нескольких секунд. Во-вторых, автоматизация рутинных задач по написанию однотипных SQL-запросов освобождает время профессиональных аналитиков и разработчиков для решения более сложных задач. В-третьих, решение открывает возможность интеграции с голосовыми интерфейсами, позволяя создавать голосовых помощников для работы с данными. Наконец, автоматическая генерация запросов снижает риск ошибок, связанных с человеческим фактором при написании сложных SQL-запросов с многочисленными JOIN и подзапросами.

Заинтересованными сторонами в решении данной задачи являются бизнес-пользователи и менеджеры, разработчики BI-систем, поставщики корпоративного ПО, облачные провайдеры, а также исследователи в области обработки естественного языка.

Требования к данным

Для успешного решения задачи Text-to-SQL набор табличных данных должен удовлетворять требованиям, представленным в таблице 1.

Таблица 1 - Требования к набору данных для задачи Text-to-SQL

Требование	Описание
Наличие разметки	Каждому естественно-языковому вопросу должен соответствовать эталонный SQL-запрос (наличие размеченных пар «вопрос - SQL»)
Разнообразие формулировок	Для одной и той же семантической сущности необходимо иметь несколько вариантов вопросов, учитывающих синонимию, разный порядок слов и разные уровни детализации
Сложность запросов	Набор данных должен включать не только простые SELECT-запросы, но и запросы с JOIN, GROUP BY, HAVING, подзапросами, вложенными условиями и агрегатными функциями (COUNT, SUM, AVG, MIN, MAX)
Объем выборки	Рекомендуемый объем обучающей выборки - от 5 000 до 10 000 пар «вопрос - SQL» для достижения приемлемого качества (>70%); для состоятельных моделей (T5-Large, CodeT5) требуется 50 000 и более примеров
Схема базы данных	Наличие полной и непротиворечивой схемы БД (метаданные: имена таблиц, столбцов, типы данных, первичные и внешние ключи); желательно наличие примеров значений (образцы данных)
Синтаксическая корректность	Все SQL-запросы должны быть синтаксически корректными и успешно выполняться на целевой СУБД (SQLite, PostgreSQL, MySQL)
Сбалансированность	Должны быть сбалансированы типы запросов (простые vs сложные), количество таблиц в запросе (от 1 до 5 и более), наличие или отсутствие агрегации
Качество текстов	Вопросы не должны содержать орфографических ошибок (либо должны содержать их контролируемо)
Масштаб базы данных	База данных должна содержать не менее 5-10 таблиц с реалистичным количеством строк (от сотен до миллионов) и разнообразными связями между таблицами

1.2. Описание выбранного набора данных

Для решения задачи преобразования естественно-языковых вопросов в SQL-запросы был выбран набор данных «text-to-sql», опубликованный пользователем Meryem Yentür на платформе Kaggle в 2024 году [2].

На странице датасета отсутствует детальное описание процесса сбора и разметки данных, а также информация о том, кем и для каких целей изначально создавался этот набор. Нет сведений о наличии экспертной оценки качества разметки. Таким образом, информация о происхождении данных и методологии их подготовки в открытых источниках не представлена, что является ограничением, которое необходимо учитывать при анализе.

Несмотря на отсутствие подробной документации, выбранный набор данных подходит для обучения модели, решающей задачу Text-to-SQL, по следующим причинам. Структура датасета напрямую соответствует решаемой задаче: он содержит естественно-языковые вопросы и соответствующие им SQL-запросы. Наличие столбца со схемой базы данных позволяет модели учитывать контекст и генерировать корректные запросы с учетом структуры таблиц и связей между ними. Объем данных (файл объемом 43,63 МБ) предположительно содержит несколько тысяч примеров, что достаточно для обучения прототипа модели. Кроме того, датасет опубликован в 2024 году, что говорит о современной структуре SQL-запросов и формулировок вопросов. Следует отметить, что вопросы в датасете представлены на английском языке, что соответствует традиционной практике построения моделей Text-to-SQL, так как подавляющее большинство существующих исследований и бенчмарков в данной области ориентированы именно на английский язык.

Данные представлены в виде одного CSV-файла с именем `dataset.csv`. Общее количество записей в датасете на момент выполнения анализа неизвестно и требует уточнения при загрузке данных. Файл содержит четыре столбца. Первый столбец представляет собой нумерацию записей (индекс). Столбец `question` содержит естественно-языковой вопрос пользователя на английском языке, представленный в виде текстовой

строки. Столбец `query` содержит SQL-запрос, соответствующий вопросу и синтаксически корректный для выполнения на целевой базе данных. Столбец `schema` содержит схему базы данных - описание таблиц, столбцов, типов данных, первичных и внешних ключей, необходимых для генерации корректного SQL-запроса. Целевой переменной в данном наборе данных является столбец `query`, поскольку именно SQL-запрос подлежит генерации моделью на основе входных данных (`question` и `schema`).

Информация о наличии пропущенных значений в датасете из описания на странице источника отсутствует. Данный вопрос будет исследован на этапе первичного анализа при загрузке и ознакомлении со структурой данных. Что касается чувствительности и конфиденциальности, то из доступного описания датасета невозможно сделать вывод о том, содержит ли он персональную информацию или потенциально чувствительные данные. Поскольку датасет предназначен для обучения моделей преобразования текста в SQL, можно предположить, что он основан на синтетических или обезличенных данных, однако окончательное заключение по данному вопросу может быть сделано только после анализа содержимого столбцов `question` и `schema`.

1.3. Описание результатов первичного анализа

1.3.1. Характеристика числовых данных

Диаграммы распределения.

На рис. 1 представлены диаграммы распределения производных числовых признаков, полученных в ходе анализа: длина вопроса, длина SQL-запроса, длина описания схемы базы данных и количество ключевых слов в запросе.




Рисунок 1. Диаграммы распределения числовых признаков

Анализ распределений позволяет сделать следующие выводы. Распределение длины вопросов имеет среднее значение 62,7 символа при медиане 59,0 символов, минимальная длина составляет 13 символов, максимальная - 985 символов. Небольшое превышение среднего над медианой свидетельствует о правосторонней асимметрии, то есть в датасете присутствует небольшое количество аномально длинных вопросов. Распределение длины SQL-запросов характеризуется средним значением 103,3 символа и медианой 90,0 символов, минимальная длина - 12 символов, максимальная - 1735 символов. Более выраженный разрыв между средним и медианой указывает на наличие заметного количества длинных сложных запросов. Длина описания схемы варьируется от 40 до 3439 символов при среднем значении 488,8 символа. Количество ключевых слов в запросе находится в диапазоне от 1 до 9, среднее значение составляет 4,2, медиана - 4,0, что говорит о преобладании запросов средней сложности.

С использованием библиотеки Seaborn были построены графики совместного распределения для трех пар признаков. На рис. 2 представлен scatterplot зависимости длины SQL-запроса от длины вопроса.




Рисунок 2. Зависимость длины SQL-запроса от длины вопроса

Наблюдается слабая положительная корреляция: коэффициент корреляции Пирсона между длиной вопроса и длиной запроса составляет 0,42. Более длинным вопросам в целом соответствуют более длинные запросы, однако разброс значений значителен, что объясняется различной сложностью семантического отображения естественного языка в структурированный запрос. Цвет точек на графике отражает количество ключевых слов в запросе.

На рис. 3 представлен boxplot, демонстрирующий распределение длины SQL-запросов в зависимости от наличия ключевого слова JOIN.




Рисунок 3. Распределение длины запросов с JOIN и без JOIN

Запросы, содержащие JOIN, в среднем значительно длиннее запросов без JOIN: медиана длины запросов с JOIN составляет 145 символов, тогда как для запросов без JOIN - 85 символов. Это логично, так как объединение таблиц требует дополнительных синтаксических конструкций. Разброс значений также больше для запросов с JOIN, что свидетельствует о разнообразии сложности таких запросов.

На рис. 4 представлен график плотности распределения длины вопросов для запросов с JOIN и без JOIN.




Рисунок 4. Плотность распределения длины вопросов в зависимости от наличия JOIN

Распределения длины вопросов для двух групп схожи, однако запросы с JOIN имеют незначительно более длинные вопросы в среднем (медиана 62 символа против 58 символов), что может указывать на то, что сложные запросы требуют более детального описания на естественном языке.

Для создания интерактивных графиков была использована библиотека Rpyplot. На рис. 5 представлен график накопленной частоты длин вопросов.



Рисунок 5. Интерактивный график накопленной частоты длин вопросов

График позволяет определить, что 80% вопросов имеют длину до 78 символов, а 95% - до 115 символов. На рис. 6 представлен график зависимости сложности запроса (количество ключевых слов) от длины вопроса с наложенной линией линейного тренда.




Рисунок 6. Зависимость сложности запроса от длины вопроса

Уравнение тренда имеет вид: $y = 0,01x + 3,70$, где y - количество ключевых слов, x - длина вопроса. Коэффициент наклона 0,01 подтверждает слабую положительную связь между признаками: увеличение длины вопроса на 100 символов в среднем приводит к увеличению количества ключевых слов на 1.

Обработка строк с нулевыми значениями. В результате анализа установлено, что пропущенные значения в датасете отсутствуют во всех столбцах (как исходных, так и производных). Таким образом, обработка строк с нулевыми значениями не требуется.

На рис. 7 представлена тепловая карта корреляций между производными числовыми признаками.

Рисунок 7. Тепловая карта корреляций между числовыми признаками




Рисунок 7. Тепловая карта корреляций между числовыми признаками

Наибольшая корреляция наблюдается между длиной запроса и количеством ключевых слов, что ожидаемо, так как большее количество ключевых слов естественным образом увеличивает длину текста запроса. Корреляция между длиной вопроса и длиной запроса составляет 0,45, что подтверждает наличие, но не строгость связи между этими величинами. Длина схемы слабо коррелирует с остальными признаками, что говорит о том, что сложность схемы базы данных не оказывает существенного влияния на длину вопроса или запроса.

На рис. 8 представлена тепловая карта, показывающая частоту совместной встречаемости ключевых слов SQL. Значения в ячейках нормированы по строкам и показывают, как часто при наличии одного ключевого слова встречается другое.




Рисунок 8. Тепловая карта совместной встречаемости ключевых слов SQL

Наибольшая совместная встречаемость наблюдается для пар «WHERE – ORDER BY» и «GROUP BY – COUNT», что соответствует типичной структуре аналитических запросов: сначала фильтрация (WHERE), затем группировка (GROUP BY) и агрегация (COUNT).

В результате проверки установлено, что полные дубликаты строк отсутствуют (0 дубликатов). Дубликаты по паре «question-query» также отсутствуют. Все 65 354 записи являются уникальными, удаление дубликатов не требуется.

Появление нетипичных выбросов по признакам. С использованием метода межквартильного размаха (IQR) были выявлены выбросы по каждому числовому признаку. Для длины вопроса верхняя граница IQR составила 108 символов, выбросами признаны 2 185 записей (3,34% от общего числа). Для длины запроса верхняя граница IQR составила 233,5 символа, выбросами признаны 1 882 записи (2,88%). Наибольшее количество выбросов (8 529 записей, 13,05%) наблюдается для длины схемы, что объясняется значительным разнообразием структур баз данных: от простых таблиц с несколькими полями до сложных схем с десятками столбцов. По количеству ключевых слов выбросы практически отсутствуют (всего 15 записей, 0,02%), что свидетельствует о том, что сложность запросов в датасете ограничена диапазоном от 1 до 9 ключевых слов.

Были выполнены три различные фильтрации данных.

Фильтрация 1: отбор запросов, содержащих JOIN. Результат: 10 317 записей (15,8% от общего числа). Пример отфильтрованного запроса: «SELECT p.project_id, p.project_details, d.document_name FROM

```
projects p LEFT JOIN documents d ON p.project_id =  
d.project_id».
```

Фильтрация 2: отбор запросов, содержащих агрегатные функции (COUNT, SUM, AVG, MAX, MIN). Результат: 48 279 записей (73,9% от общего числа). Это говорит о том, что большинство запросов в датасете решают аналитические задачи, требующие вычисления итоговых показателей.

Фильтрация 3: отбор запросов, у которых длина вопроса превышает 100 символов (длинные вопросы) и количество ключевых слов больше 5 (сложные запросы). Результат: 686 записей (1,05% от общего числа). Данная фильтрация выделяет наиболее сложные сценарии использования, которые представляют особый интерес для оценки качества модели.

Для оценки устойчивости модели к искажениям входных данных был выполнен эксперимент по добавлению шума в два признака: `question` и `query` (целевой признак не затрагивался). В 1 000 случайно выбранных записей в столбец `question` был добавлен символьный шум (замена 3% символов на случайные буквы или цифры), а в столбец `query` - регистровый шум (случайное изменение регистра ключевых слов). На рис. 9 представлено сравнение распределения длин исходных и зашумленных вопросов.




Рисунок 9. Влияние добавления шума на распределение длин вопросов.

Добавление символьного шума практически не изменило распределение длин вопросов, так как замены символов не влияют на длину строки. Однако в содержательном плане зашумленные вопросы становятся менее читаемыми и могут содержать синтаксически некорректные конструкции. Потенциальная ценность данного действия заключается в возможности аугментации данных для повышения робастности модели к опечаткам и нестандартному форматированию пользовательских вопросов.

Для упрощения анализа и возможности группировки данных была выполнена категоризация числовых признаков. Вопросы были разделены на три категории по длине: короткие (менее 50 символов) - 18 359 записей (28,1% от общего числа), средние (50-100 символов) - 43 659 записей (66,8%), длинные (более 100 символов) - 3 336 записей (5,1%). Запросы были разделены на три категории по сложности (количеству ключевых слов): простые (1-3 ключевых слова) - 17 365 записей (26,6%), средние (4-6 ключевых слов) - 45 992 записи (70,4%), сложные (7-9 ключевых слов) - 1 997 записей (3,0%).

В ходе анализа было обнаружено, что SQL-запросы в датасете используют различные стили форматирования (нижний регистр, верхний регистр, смешанный). Для унификации все запросы были приведены к верхнему регистру. Также в столбце `schema` были унифицированы обозначения типов данных (`INTEGER` → `INT`, `TEXT` → `VARCHAR`). Данные преобразования не изменяют семантику данных, но упрощают их дальнейшую обработку и анализ.

После выполнения всех преобразований была проведена фильтрация данных для удаления экстремальных выбросов (длина вопроса более 200 символов или длина запроса более 400 символов). На рис. 10 представлено сравнение распределений длин вопросов и запросов до и после фильтрации.




Рисунок 10. Сравнение распределений до и после фильтрации выбросов

В результате фильтрации было удалено 256 записей (0,39% от общего числа). Основные статистические характеристики распределений изменились незначительно, что подтверждает корректность выполненной фильтрации: удалены только экстремальные выбросы, не влияющие на общую картину.

Для выявления наиболее популярных структур баз данных была выполнена группировка записей по столбцу `schema`. На рис. 11 представлены топ-10 схем по частоте использования.




Рисунок 11. Топ-10 схем баз данных по частоте использования

Наиболее часто встречающейся схемой является `apartment_bookings` (1 941 запись, 2,97% от общего числа). В целом топ-10 схем охватывает лишь около 10% всех записей, что говорит о высоком разнообразии структур данных в датасете.

1.3.2. Характеристика категориальных данных

В датасете категориальными признаками являются столбцы `question`, `query` и `schema` (каждый из них представляет собой текстовую строку). Признак `has_join` (производный) имеет две категории: запросы без JOIN (55 037 записей, 84,2%) и запросы с JOIN (10 317 записей, 15,8%).

На рис. 12 представлена круговая диаграмма распределения запросов по категориям сложности (на основе количества ключевых слов).

Рисунок 12. Распределение запросов по категориям сложности




Рисунок 12. Распределение запросов по категориям сложности

Преобладающую долю (70,4%) составляют запросы средней сложности, что делает датасет сбалансированным для обучения моделей, способных обрабатывать типовые аналитические задачи. Простые запросы составляют 26,6%, а сложные - лишь 3,0%.

Для возможности использования категориальных признаков в некоторых моделях машинного обучения было выполнено частотное кодирование (frequency encoding) признака `schema`: каждое уникальное значение схемы было заменено на частоту его встречаемости в датасете. Также для признака `has_join` было выполнено Label Encoding: значение False заменено на 0, True - на 1.

При анализе редких категорий было установлено, что 210 схем баз данных (22,2% от общего числа уникальных схем) встречаются в датасете

менее 10 раз. Для этих редких схем была выполнена агрегация в обобщающую категорию «other_schema». После агрегации количество уникальных схем сократилось с 947 до 738, что упрощает дальнейший анализ и снижает риск переобучения модели на редких примерах.

На основе анализа признака `query` была введена новая категория «`query_level`», характеризующая уровень сложности запроса. Категория определяется на основе трех критериев: наличие JOIN, наличие GROUP BY, наличие агрегатных функций. Выделены четыре уровня сложности: low (низкий) - 14 747 записей (22,6%), medium (средний) - 23 121 запись (35,4%), high (высокий) - 21 753 записи (33,3%), very high (очень высокий) - 5 733 записи (8,8%). На рис. 13 представлено распределение запросов по уровням сложности.




Рисунок 13. Распределение запросов по уровню сложности (новая категория)

Данная категория может быть использована в качестве целевого признака для задач классификации сложности запроса или для стратификации выборки при обучении модели.

1.3.3. Особенности и потенциальные риски использования датасета

Датасет «text-to-sql» был создан для обучения моделей преобразования естественно-языковых вопросов в SQL-запросы. Основная особенность предметной области заключается в необходимости одновременного понимания естественного языка, структуры базы данных (схемы) и синтаксиса SQL. Эта особенность накладывает ограничения на применимость датасета: он не может быть использован для задач, не связанных с реляционными базами данных или SQL. Влияние этой особенности на решение задач состоит в том, что модель должна обучаться на парах «вопрос - схема - запрос», а не только на «вопрос - запрос», что повышает требования к качеству и полноте столбца schema.

Гипотезы для корректного использования датасета.

Гипотеза 1. Длина вопроса положительно коррелирует со сложностью SQL-запроса (количеством ключевых слов, наличием JOIN, подзапросов). Данная гипотеза подтверждается результатами корреляционного анализа: коэффициент корреляции между длиной вопроса и длиной запроса составляет 0,42, между длиной вопроса и количеством ключевых слов - 0,38. Однако наличие выбросов (короткие вопросы со сложными запросами и наоборот) указывает на то, что длина не является единственным и достаточным предиктором сложности.

Гипотеза 2. Разнообразие схем баз данных (947 уникальных схем) позволяет модели обобщать знания на новые, не встречавшиеся в обучении предметные области. Наличие 210 редких схем (встречаемость менее 10 раз) подтверждает, что датасет содержит множество примеров, которые могут служить проверкой способности модели к обобщению. Для подтверждения гипотезы необходимо оценить качество модели на запросах к схемам, не присутствовавшим в обучающей выборке.

Гипотезы для вероятного неэтичного использования датасета.

Гипотеза 1 (неэтичное использование). Модель, обученная на данном датасете, может быть использована для несанкционированного доступа к базам данных. Если злоумышленник получит доступ к интерфейсу, преобразующему естественные вопросы в SQL, он может сформулировать вопрос таким образом, чтобы сгенерированный запрос вернул данные, на которые у пользователя нет прав (например, «show me all user passwords»). Защита от такого использования требует внедрения дополнительных механизмов авторизации и фильтрации запросов на стороне приложения.

Гипотеза 2 (неэтичное использование). Датасет может быть использован для создания систем, генерирующих SQL-запросы, нарушающие политику конфиденциальности. Хотя в данном датасете не содержится реальных персональных данных (все данные синтетические), обученная модель может перенести паттерны генерации запросов на реальные базы данных, что потенциально может привести к извлечению чувствительной информации.

Потенциальные возможности расширения датасета. Датасет можно расширить следующими признаками: язык вопроса (в текущей версии - только английский), временная метка создания записи (для анализа эволюции сложности запросов), идентификатор пользователя (для анализа индивидуальных паттернов формулирования вопросов), экспертная оценка сложности запроса (от 1 до 5). Добавление этих признаков позволит решать новые задачи: адаптация модели под конкретного пользователя (personalization), анализ трендов изменения пользовательских предпочтений, создание рекомендательной системы для обучения SQL. Кроме того, расширение датасета за счет вопросов на

русском языке позволит решать задачу Text-to-SQL для русскоязычных пользователей, что является актуальной и востребованной задачей.

2. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ДАННЫХ С ВРЕМЕННЫМИ РЯДАМИ

2.1. Постановка задачи

В современной промышленности широкое распространение получили системы мониторинга состояния оборудования, которые генерируют огромные массивы данных в виде временных рядов - показаний датчиков вибрации, температуры, давления и других параметров. Ключевой задачей интеллектуального анализа таких данных является обнаружение аномалий в поведении оборудования, позволяющее своевременно выявлять развивающиеся дефекты и предотвращать аварийные остановки производства. Одним из самых распространённых и информативных методов диагностики вращающегося оборудования (подшипников, редукторов, турбин) является анализ вибрационных сигналов, так как вибрация чутко реагирует на начальные стадии развития дефектов.

Тип задачи

Выбранная задача относится к классу обнаружения аномалий в многомерных временных рядах. В терминах машинного обучения её можно классифицировать как задачу обучения без учителя (unsupervised learning), когда аномалии (дефекты) являются редкими событиями и могут не иметь явной разметки. Основная цель - не просто фиксация факта превышения порогового значения, а обнаружение коллективных аномалий - устойчивых паттернов изменения вибрации, свидетельствующих о развитии дефекта подшипника.

Входные и выходные данные

На вход модели подаётся многомерный временной ряд вибрационных сигналов, полученных с нескольких акселерометров, установленных на корпусах подшипников. Каждый канал временного ряда представляет собой последовательность значений виброускорения (в единицах g), измеренную с высокой частотой дискретизации (в данном случае 20 кГц). На выходе модель должна определить состояние подшипника (нормальное / дефектное) и

локализовать источник аномалии (указать, на каком канале / датчике развивается дефект).

Предметная область

Задача относится к области промышленной диагностики и предиктивной аналитики. Область применения охватывает такие сферы, как:

- мониторинг состояния подшипников в электродвигателях, генераторах, насосах и компрессорах;
- диагностика редукторов и трансмиссий в горнодобывающей и нефтегазовой промышленности;
- системы контроля состояния шпинделей металлорежущих станков;
- оценка технического состояния ветрогенераторов и турбин авиационных двигателей.

Практическая значимость

Решение задачи обнаружения аномалий в вибрационных временных рядах обладает высокой практической ценностью. Во-первых, своевременное обнаружение дефектов подшипников позволяет предотвратить аварийные остановки критически важного оборудования, что сокращает простои производства и предотвращает каскадные отказы. Во-вторых, переход от ремонта по регламенту к обслуживанию по фактическому состоянию позволяет оптимизировать затраты на запасные части и ремонтные работы. В-третьих, автоматизация процесса мониторинга с помощью интеллектуальных алгоритмов снижает нагрузку на экспертов-диагностов и позволяет обрабатывать данные с тысяч датчиков в реальном времени.

Заинтересованными сторонами являются: промышленные предприятия, эксплуатирующие вращающееся оборудование; сервисные компании, предоставляющие услуги по мониторингу состояния; производители подшипников и редукторов; разработчики систем промышленного IoT.

Требования к данным

Для успешного решения задачи обнаружения аномалий в вибрационных данных набор данных должен удовлетворять требованиям, представленным в таблице 2.1.

Таблица 2 - Требования к набору данных для задачи обнаружения аномалий во временных рядах

Требование	Описание
Наличие временной метки	Каждое измерение должно быть привязано к точному времени; временные интервалы между измерениями должны быть равномерными
Многомерность	Наличие нескольких каналов (датчиков) для локализации источника аномалии
Высокая частота дискретизации	Частота должна быть не менее 10-20 кГц для захвата высокочастотных ударных импульсов, характерных для дефектов подшипников
Длительность эксперимента	Эксперимент должен продолжаться до момента появления явного дефекта (эксперимент «до разрушения»), чтобы в данных присутствовала как «норма», так и деградация
Репрезентативность	Данные должны соответствовать реальным условиям эксплуатации: наличие шумов, возможных пропусков в данных из-за сбоев системы сбора
Объем выборки	Достаточное количество измерений для анализа трендов (не менее нескольких сотен замеров на канал)

2.2. Описание выбранного набора данных

Для решения задачи обнаружения аномалий в вибрационных временных рядах был выбран набор данных IMS Bearing Dataset (Set 1), опубликованный Центром интеллектуальных систем технического обслуживания (NSF I/UCR Center for Intelligent Maintenance Systems) Университета Цинциннати при поддержке компании Rexnord Corp. Данные доступны для свободного скачивания на платформе NASA Data Portal и в репозитории GitHub [3].

Краткая информация о сборе и разметке

Эксперимент проводился на специальном стенде, где на одном валу были установлены четыре подшипника Rexnord ZA-2115. Частота вращения вала поддерживалась постоянной на уровне 2000 об/мин с помощью АС-двигателя, а радиальная нагрузка на подшипники составляла 6000 фунтов (около 2722 кг) и создавалась пружинным механизмом. Смазка подшипников была принудительной. Данные собирались с помощью акселерометров PCB 353B33 высокой чувствительности, установленных на корпусах подшипников. Частота дискретизации составляла 20 кГц, а длительность одного снятого замера - 1 секунда (20480 точек). Замеры производились с интервалом 10 минут (первые 43 замера - с интервалом 5 минут). Эксперимент продолжался до появления явных дефектов подшипников. Разметка дефектов выполнена на основе пост-экспериментального анализа: в подшипнике 3 был обнаружен дефект внутреннего кольца и тела качения, в подшипнике 4 - дефект тела качения. Таким образом, данные содержат как эталонный участок нормальной работы (начало эксперимента), так и развитие катастрофических дефектов (конец эксперимента).

Обоснование выбора

Выбранный набор данных подходит для обучения модели, решающей задачу обнаружения аномалий, по следующим причинам. Во-первых, данные представляют собой эксперимент «до разрушения»: в наборе присутствует как длительный период нормальной работы, так и прогрессирующая деградация подшипников, что позволяет обучать модели на примерах развития дефекта во времени. Во-вторых, высокая частота дискретизации (20 кГц) позволяет захватывать высокочастотные ударные импульсы, характерные для начальных стадий дефектов. В-третьих, наличие нескольких каналов даёт возможность решать задачу локализации аномалии - определять, какой именно датчик (канал) фиксирует аномальный рост вибрации.

Структура данных

Набор данных Set 1 представлен в виде набора текстовых файлов (формат ASCII). Общее количество файлов - 2156. Каждый файл содержит

20480 значений амплитуды вибрации (с плавающей точкой), записанных с частотой 20 кГц, что соответствует 1 секунде сигнала. Имя файла имеет формат ГГГГ.ММ.ДД.ЧЧ.ММ.НомерКанала, что позволяет определить временную метку начала записи и идентифицировать номер канала (датчика).

В ходе загрузки данных было установлено, что в наборе присутствует 25 уникальных каналов (датчиков) со следующими номерами: 3, 7, 9, 11, 13, 14, 15, 17, 19, 21, 24, 30, 32, 35, 36, 38, 39, 44, 46, 48, 51, 54, 55, 56, 58. При этом каналы не имеют общих временных меток, то есть каждый канал представляет собой независимый временной ряд со своей шкалой времени. Данная особенность была учтена при дальнейшем анализе: корреляция между каналами по временной оси не рассчитывалась.

Перечень признаков

Для каждого файла (одной секунды вибрации) были вычислены статистические признаки, используемые для анализа. Перечень признаков представлен в таблице 3. Признаки *kurtosis* (эксцесс) и *skewness* (асимметрия) были исключены из анализа, так как в процессе загрузки данных было установлено, что они имеют тип *object* и содержат массивы, а не скалярные числовые значения.

Таблица 3 - Признаки, полученные из вибрационного сигнала

Признак	Семантика	Тип данных	Пример значения
timestamp	Временная метка начала измерения	datetime	2003-10-22 12:06:00
channel	Номер канала (датчика)	Целочисленный	3, 7, 13, 24, 56
mean	Среднее арифметическое сигнала	числовой (float)	-0,0928
std	Стандартное отклонение сигнала	числовой (float)	0,0943
rms	Среднеквадратичное значение (Root Mean Square)	числовой (float)	0,1226
peak	Пиковое значение (максимум модуля)	числовой (float)	0,784

crest_factor	Пик-фактор (peak / rms)	числовой (float)	6,393
--------------	-------------------------	------------------	-------

Наличие пропусков

Информация о наличии пропусков в исходных данных на странице источника отсутствовала. В ходе первичного анализа было установлено, что пропущенные значения в загруженных данных отсутствуют. Все 2156 записей содержат полные и корректные данные.

Чувствительность и конфиденциальность

Данные эксперимента не содержат персональной информации или чувствительных данных. Все измерения представляют собой технические показатели работы подшипников на испытательном стенде. В описании набора данных отсутствует информация о необходимости соблюдения каких-либо этических норм или требований к конфиденциальности. Набор данных может использоваться без ограничений в научных и образовательных целях.

2.3. Описание результатов первичного анализа

В данном подразделе представлены результаты последовательного выполнения этапов анализа временных рядов. Анализ проводился на основе набора данных IMS Bearing Set 1.

2.3.1. Этап 1. Загрузка и первичное знакомство с данными

На первом этапе выполнена загрузка данных из 2156 текстовых файлов, каждый из которых содержит 20 480 значений вибрации (1 секунда записи с частотой 20 кГц). Имена файлов имеют формат ГГГГ.ММ.ДД.ЧЧ.ММ.НомерКанала, что позволило извлечь временные метки и номера каналов.

В результате загрузки сформирован DataFrame, содержащий 2156 записей и 7 столбцов: timestamp, channel, mean, std, rms, peak,

crest_factor. В ходе загрузки было установлено, что в наборе присутствует 25 уникальных каналов со следующими номерами: 3, 7, 9, 11, 13, 14, 15, 17, 19, 21, 24, 30, 32, 35, 36, 38, 39, 44, 46, 48, 51, 54, 55, 56, 58. Диапазон временных меток охватывает период с 22 октября 2003 г. по 25 ноября 2003 г., общая длительность эксперимента составляет 34 дня.

Пропущенные значения в загруженных данных отсутствуют. Признаки kurtosis (эксцесс) и skewness (асимметрия) были исключены из анализа, так как при расчёте возвращали массивы, а не скалярные значения.

2.3.2. Этап 2. Визуализация исходных данных

На рис. 14 представлена динамика среднеквадратичного значения (RMS) для всех 25 каналов.




Рисунок 14 - Динамика RMS по всем каналам

Большинство каналов демонстрируют стационарное поведение с уровнем RMS в диапазоне 0,14-0,16 g, что соответствует нормальной работе подшипников. Каналы 56, 32, 24, 13, 3 показывают рост RMS к концу эксперимента, что является характерным признаком развивающихся дефектов.

На рис. 15 выделены каналы с наибольшим ростом RMS.




Рисунок 15 - Каналы с наибольшим ростом RMS

Лидером является канал 56 с ростом 95,6% (с 0,1585 до ~0,3 g), вторым - канал 32 с ростом 25,7% (с 0,1654 до 0,2080 g). На графики наложены линии линейного тренда, подтверждающие устойчивый характер роста. Типы обнаруженных аномалий:

- коллективные аномалии - устойчивый рост RMS на каналах 56, 32, 24, 13, 3 в конце эксперимента;
- точечные аномалии - единичные выбросы (менее 1,5% записей);
- контекстные аномалии - не обнаружены (сезонные паттерны отсутствуют).

2.3.3. Этап 3. Статистический анализ

В табл. 4 представлены статистические характеристики RMS для первых 10 каналов.

Таблица 4 - Статистики RMS по каналам (первые 10)

Канал	RMS_mean, g	RMS_std, g	RMS_min, g	RMS_max, g
3	0,1536	0,0016	0,1510	0,1620
7	0,1507	0,0010	0,1491	0,1562
9	0,1494	nan	0,1494	0,1494
11	0,1612	nan	0,1612	0,1612
13	0,1248	0,0022	0,1193	0,1443
14	0,1488	nan	0,1488	0,1488
15	0,1479	nan	0,1479	0,1479
17	0,1489	0,0018	0,1444	0,1569
19	0,1508	0,0039	0,1480	0,1536
21	0,2237	0,0942	0,1571	0,2904

Среднее значение RMS для исправных каналов составляет 0,14-0,16 g, для канала 21 (аномальный) - 0,2237 g. Каналы 9, 11, 14, 15 имеют нулевое стандартное отклонение (только по одной записи), что делает их непригодными для анализа временных трендов.

В табл. 5 представлена общая статистика по всем 2156 записям.

Таблица 5 - Общая статистика по всем каналам

Показатель	mean	std	rms	peak	crest_factor
count	2156,0	2156,0	2156,0	2156,0	2156,0
mean	-0,1143	0,0992	0,1516	1,1267	7,2669
std	0,0059	0,0146	0,0128	0,6416	3,5268
min	-0,1292	0,0789	0,1193	0,5440	4,1661
25%	-0,1162	0,0932	0,1484	0,7740	5,2915
50%	-0,1158	0,0943	0,1494	0,8670	5,8670
75%	-0,1153	0,1014	0,1546	1,1280	7,2833
max	-0,0844	0,3117	0,3232	5,0000	29,0918

Разброс RMS составляет от 0,1193 до 0,3232 g, разброс Peak - от 0,544 до 5,000 g. На рис. 16 представлены гистограммы распределения RMS для 25 каналов.



Рисунок 16 - Распределение RMS по каналам

Для исправных каналов распределение близко к нормальному с узким пиком в области 0,14-0,16 g. Дефектные каналы (56, 32, 21) демонстрируют асимметрию и появление значений выше 0,18 g.

Анализ частоты дискретизации.

Частота дискретизации внутри каждого файла составляет 20 кГц (20 480 точек за 1 секунду). Интервал между последовательными записями для большинства каналов с достаточным количеством данных (каналы 3, 7, 13, 17) составляет 10 минут, что подтверждается вычисленным медианным интервалом. Канал 3 имеет более высокую частоту записи - интервал 5 минут (158 записей). Каналы 9, 11, 14, 15 содержат только по одной записи, что делает их непригодными для анализа временных трендов.

2.3.4. Этап 4. Анализ пропусков и выбросов

Пропущенные значения в данных отсутствуют. В табл. 6 представлены результаты выявления выбросов по правилу трёх сигм для первых 10 каналов.

Таблица 6 - Выбросы по правилу трёх сигм (первые 10 каналов)

Канал	Количество выбросов	Доля выбросов, %
3	1	0,63
7	1	1,47
9	0	0,00
11	0	0,00
13	2	1,31
14	0	0,00
15	0	0,00
17	1	2,56
19	0	0,00
21	0	0,00

Доля выбросов не превышает 2,5% для всех каналов, что свидетельствует о высоком качестве данных. На рис. 17 представлена диаграмма размаха RMS для первых 15 каналов.




Рисунок 17 - Диаграмма размаха RMS (первые 15 каналов)

Канал 21 выделяется аномально высокими значениями (медиана около 0,2237 g, верхняя граница до 0,29 g). Каналы 32 и 56 также демонстрируют повышенный разброс по сравнению с большинством каналов.

2.3.5. Этап 5. Анализ диапазонов значений

Диапазоны значений по анализируемым метрикам:

- RMS: от 0,1193 до 0,3232 g;
- Peak: от 0,544 до 5,000 g;
- Crest Factor: от 4,166 до 29,092.

Различия в масштабах между каналами являются существенными: коэффициент отношения максимального Peak к максимальному RMS составляет 15,5. Для исправных каналов RMS варьируется в узком диапазоне 0,14-0,16 g, тогда как для дефектных каналов значения достигают 0,20-0,32 g. Перед обучением моделей машинного обучения рекомендуется применять стандартизацию (StandardScaler) для приведения признаков к единому масштабу.

2.3.6. Этап 6. Корреляционный анализ

В ходе анализа было установлено, что каналы не имеют общих временных меток (каждый канал представляет собой независимый временной ряд). По этой причине корреляционный анализ между каналами по временной оси не выполнялся. Вместо этого построена корреляционная матрица между статистическими признаками (рис. 18, табл. 7).

Таблица 7 - Корреляционная матрица признаков

Признак	mean	std	rms	peak	crest_factor
mean	1,000	-0,301	-0,567	-0,184	-0,137
std	-0,301	1,000	0,952	0,756	0,632
rms	-0,567	0,952	1,000	0,681	0,550
peak	-0,184	0,756	0,681	1,000	0,982
crest_factor	-0,137	0,632	0,550	0,982	1,000

Рисунок 18 - Корреляция между статистическими признаками




Рисунок 18 - Корреляционная матрица признаков

Наиболее сильные корреляции наблюдаются между парами:

- `rms` и `std` (0,952) - ожидаемо, так как оба характеризуют разброс сигнала;
- `peak` и `crest_factor` (0,982) - фактически дублирующие признаки, что указывает на возможную избыточность.

Признак `mean` слабо коррелирует с остальными (коэффициенты от -0,567 до -0,137), что объясняется центрированностью данных около нуля.

2.3.7. Этап 7. Поиск и анализ шумов

Для анализа шума выбран канал 56 (лидер по росту RMS). На рис. 19 представлено сглаживание исходного RMS с помощью скользящего среднего с окном 20.



Рисунок 19 - Сглаживание RMS (Канал 56)

Красная линия тренда наглядно демонстрирует устойчивый рост вибрации к концу эксперимента. Расчёт отношения сигнал/шум (SNR) выполнен по формуле:

$$SNR = 10 * \log_{10} \frac{\sigma_{\text{сигнал}}^2}{\sigma_{\text{шум}}^2}$$

Результаты расчёта:

- дисперсия сигнала: 0,000007;
- дисперсия шума: 0,000179;
- SNR = -13,93 дБ.

Согласно шкале интерпретации SNR (табл. 8), значение -13,93 дБ соответствует оценке «Плохо»: шум сильнее полезного сигнала. Данный результат характерен для сырых вибрационных данных и не является критическим, однако перед обучением моделей рекомендуется применять фильтрацию.

Таблица 8 - Интерпретация значений SNR

SNR, дБ	Качественная оценка	Что это означает на практике
> 20	Отлично	Шум практически незаметен
10-20	Хорошо	Сигнал доминирует
0-10	Удовлетворительно	Требуется фильтрация
< 0	Плохо	Шум сильнее сигнала

На рис. 20 представлена гистограмма распределения остатков (шума) для канала 56.




Рисунок 20 - Распределение шума (Канал 56)

Распределение близко к нормальному (колоколообразная форма), что свидетельствует о случайном характере шума и отсутствии систематических искажений. Эксцесс распределения близок к нулю, асимметрия не выражена. Для подавления шума рекомендуется использовать скользящее среднее (как показано на рис. 19) или медианный фильтр.

3. ПЕРВИЧНЫЙ АНАЛИЗ НАБОРА ДАННЫХ С ИЗОБРАЖЕНИЯМИ

3.1. Постановка задачи

В современной промышленности и строительстве обеспечение безопасности персонала является критически важной задачей. Одним из ключевых требований охраны труда является использование средств индивидуальной защиты (СИЗ), таких как каски, перчатки, защитные очки и сигнальные жилеты. Нарушение этих требований может привести к травмам, несчастным случаям или летальным исходам. Для автоматизации контроля за соблюдением техники безопасности разрабатываются системы компьютерного зрения, способные в реальном времени анализировать видеопоток с камер наблюдения и выявлять сотрудников, не использующих необходимые СИЗ. Решение данной задачи связано с детекцией объектов и распознаванием нарушений на изображениях.

Тип задачи

Задача относится к классу детекции объектов (object detection). В терминах машинного обучения её можно классифицировать как задачу управления несколькими объектами (multi-object detection), где модель должна одновременно решать две подзадачи: локализацию (определение координат bounding box) и классификацию (определение класса объекта). Промежуточные подзадачи включают распознавание конкретных типов СИЗ (каска, жилет, очки, перчатки) и выявление нарушений (отсутствие обязательных СИЗ).

Входные и выходные данные

На вход модели подаются цветные изображения, полученные с камер видеонаблюдения на строительной площадке или промышленном предприятии. Входные данные представляют собой RGB-изображения фиксированного размера (в выбранном наборе данных - 640×640 пикселей). На выходе модель должна сформировать список обнаруженных объектов, где для каждого объекта указываются координаты ограничивающего прямоугольника (bounding box) в формате (x_center, y_center, width, height), а

также идентификатор класса, к которому принадлежит объект (например, «Hardhat» - каска, «Gloves» - перчатки, «NO-Hardhat» - отсутствие каски).

Предметная область

Задача относится к широкому кругу предметных областей, связанных с обеспечением безопасности труда. Область применения охватывает такие сферы, как:

- контроль соблюдения техники безопасности на строительных площадках;
- мониторинг персонала на промышленных предприятиях и заводах;
- обеспечение безопасности в горнодобывающей и нефтегазовой промышленности;
- контроль использования СИЗ в логистических центрах и складских комплексах.

Практическая значимость

Решение задачи детекции СИЗ и выявления нарушений обладает высокой практической ценностью. Во-первых, автоматизация контроля позволяет круглосуточно отслеживать соблюдение правил безопасности без привлечения дополнительного персонала, что снижает нагрузку на службы охраны труда. Во-вторых, своевременное обнаружение нарушений (отсутствие каски, перчаток или жилета) позволяет предотвратить травматизм и несчастные случаи, связанные с человеческим фактором. В-третьих, внедрение таких систем способствует формированию культуры безопасности и дисциплинирует персонал, так как сотрудники осознают, что их действия постоянно контролируются. Наконец, возможность интеграции с системами видеоаналитики позволяет вести статистику нарушений, выявлять наиболее проблемные участки и принимать адресные управленческие решения.

Заинтересованными сторонами являются службы охраны труда и техники безопасности на предприятиях, руководители строительных и

промышленных объектов, разработчики систем видеонаблюдения и видеоаналитики, а также государственные надзорные органы.

Требования к данным

Для успешного решения задачи детекции СИЗ и выявления нарушений набор изображений должен удовлетворять требованиям, представленным в таблице 9.

Таблица 9 - Требования к набору данных для задачи детекции СИЗ

Требование	Описание
Наличие разметки	Каждое изображение должно иметь аннотацию в формате детекции (YOLO, COCO, Pascal VOC) с указанием bounding box и класса для каждого объекта СИЗ
Разнообразие сцен	Изображения должны охватывать различные ракурсы (вид спереди, сбоку, сверху), разные условия освещения (день, вечер, помещение) и различные фоны (строительная площадка, цех, склад)
Баланс классов	Должен быть обеспечен приемлемый баланс между классами объектов; при наличии дисбаланса он должен быть явно указан и продуманы способы компенсации
Полнота разметки	На изображении должны быть размечены все объекты целевых классов. Если на фото присутствуют три каски, но размечена только одна, модель будет «наказана» за правильное обнаружение неразмеченных объектов
Объем выборки	Рекомендуемый объем - от 1 000 до 10 000 изображений с несколькими объектами на каждом для обеспечения устойчивого обучения модели
Формат изображений	Изображения должны быть в распространённых форматах (JPEG, PNG) с разрешением не менее 512×512 пикселей для уверенного распознавания мелких объектов
Наличие «отрицательных» классов	Для выявления нарушений необходимы классы, обозначающие отсутствие СИЗ (например, «NO-Hardhat», «NO-Gloves»)

3.2. Описание выбранного набора данных

Для решения задачи детекции средств индивидуальной защиты и выявления нарушений был выбран набор данных «PPE Dataset YOLOv8»,

находящийся в директории `valid`, опубликованный пользователем Shlok Raval на платформе Kaggle[4]. Датасет загружен локально и имеет структуру, соответствующую формату YOLO: корневая директория `dataset` содержит папку `images` с изображениями в формате JPEG, папку `labels` с текстовыми файлами аннотаций в формате YOLO и файл конфигурации `data.yaml`, в котором перечислены классы (14 классов) и пути к данным.

На странице датасета на платформе Kaggle отсутствует детальное описание процесса сбора и разметки данных, а также информация о том, кем и для каких целей изначально создавался этот набор. Нет сведений о наличии экспертной оценки качества разметки. Предположительно, данные были собраны путём веб-скрейпинга изображений с открытых источников или сгенерированы с использованием синтетических методов. Информация о происхождении данных и методологии их подготовки в открытых источниках не представлена, что является ограничением, которое необходимо учитывать при анализе. Однако отсутствие подробной документации не является критическим, так как сам набор данных широко используется в образовательных и исследовательских проектах по компьютерному зрению.

Несмотря на отсутствие подробной документации, выбранный набор данных подходит для обучения модели, решающей задачу детекции СИЗ, по следующим причинам. Во-первых, структура датасета напрямую соответствует решаемой задаче: он содержит изображения с людьми в различных рабочих условиях и аннотации в формате YOLO, который является индустриальным стандартом для задач детекции. Во-вторых, набор включает 14 классов, среди которых присутствуют как непосредственно средства защиты («Hardhat», «Gloves», «Goggles», «Safety Vest», «Mask»), так и классы, обозначающие нарушения («NO-Hardhat», «NO-Gloves», «NO-Goggles», «NO-Mask», «NO-Safety Vest»), что позволяет решать не только задачу детекции, но и задачу контроля соблюдения правил безопасности. В-третьих, объем данных (8 814 изображений, 22 077 аннотированных объектов) является достаточным для обучения глубоких нейронных сетей, особенно с использованием техник

аугментации и transfer learning. Наконец, все изображения имеют единое разрешение 640×640 пикселей, что соответствует минимальным требованиям и упрощает предварительную обработку.

Структура данных

Данные представлены в виде директорий, организованных в соответствии со стандартом YOLO. Общее количество изображений в наборе составляет 8 814, количество файлов аннотаций - также 8 814. Файл конфигурации `data.yaml` содержит список из 14 классов: `Fall-Detected`, `Gloves`, `Goggles`, `Hardhat`, `Ladder`, `Mask`, `NO-Gloves`, `NO-Goggles`, `NO-Hardhat`, `NO-Mask`, `NO-Safety Vest`, `Person`, `Safety Cone`, `Safety Vest`.

Перечень признаков

Для каждого изображения доступны следующие характеристики:

- **имя файла** - уникальный идентификатор изображения в формате `[name].jpg`;
- **разрешение** - 640х640 пикселей (единое для всех изображений);
- **цветовая модель** - RGB (стандартная для JPEG-изображений).

Для каждого объекта на изображении доступны следующие признаки (хранятся в соответствующем txt-файле в папке `labels`):

- **class_id** - целочисленный идентификатор класса (от 0 до 13), соответствующий одному из 14 классов СИЗ или нарушений;
- **x_center** - нормализованная координата центра bounding box по оси X (число с плавающей точкой в диапазоне [0,1]);
- **y_center** - нормализованная координата центра bounding box по оси Y (число с плавающей точкой в диапазоне [0,1]);
- **width** - нормализованная ширина bounding box (число с плавающей точкой в диапазоне [0,1]);
- **height** - нормализованная высота bounding box (число с плавающей точкой в диапазоне [0,1]).

Целевой переменной в данном наборе данных является совокупность всех bounding box с их классами, поскольку именно эта информация подлежит предсказанию моделью на основе входного изображения.

Наличие пропусков

Информация о наличии пропусков в данных из описания на странице источника отсутствовала. В ходе первичного анализа было установлено, что пропущенные значения в данных отсутствуют. Из 8 814 изображений 210 (2,4%) не содержат аннотированных объектов (пустые txt-файлы или файлы без записей). Остальные 8 604 изображения содержат аннотации в полном объёме. Все изображения имеют корректные имена файлов, соответствующие именам файлов аннотаций.

Чувствительность и конфиденциальность

Данные, представленные в наборе, представляют собой изображения людей в рабочих условиях (строительные площадки, промышленные объекты). На изображениях могут присутствовать узнаваемые лица людей, что потенциально может нарушать конфиденциальность, если эти изображения были собраны без согласия. На странице источника отсутствует информация о том, было ли получено согласие на использование изображений. В описании набора данных на Kaggle не указано, применялись ли методы анонимизации (размытие лиц, удаление идентифицирующей информации). Данный аспект требует осторожности при использовании набора в коммерческих или публичных проектах. Для учебных и исследовательских целей, в рамках курсового проекта, использование данных допустимо, однако при возможном дальнейшем внедрении системы необходимо учитывать требования законодательства о персональных данных.

3.3. Описание результатов первичного анализа

В данном подразделе представлены результаты последовательного выполнения всех этапов анализа изображений, предусмотренных учебно-методическими материалами: анализ количества и баланса классов,

демонстрация примеров изображений, оценка качества изображений и анализ аннотаций.

3.3.1. Анализ количества и баланса классов

На первом этапе был проведен анализ распределения объектов по классам, количества объектов на одно изображение и общего покрытия аннотациями.

В результате загрузки и парсинга набора данных установлено, что датасет содержит 8 814 изображений, на которых размечено 22 077 объектов. Из общего числа изображений 210 (2,4%) не содержат ни одного аннотированного объекта (пустые аннотации). Остальные 8 604 (97,6%) изображения содержат хотя бы один объект. Среднее количество объектов на одно изображение составляет 2,57, что соответствует требованиям инструкции для задач детекции (наличие нескольких объектов на изображении).

На рис. 21 представлен комплексный график, включающий распределение объектов по классам, распределение количества объектов на изображение и долю изображений с объектами и без них.




Рисунок 21 - Распределение объектов по классам, количество объектов на изображение и покрытие аннотациями

Анализ распределения объектов по классам (левая диаграмма рис. 21) выявляет существенный дисбаланс. Класс «Hardhat» (каска) является доминирующим и составляет 8 952 объекта (40,5% от общего числа). Вторым

по распространенности является класс «Safety Cone» (дорожный конус) с 3 016 объектами (13,7%). Класс «NO-Hardhat» (отсутствие каски) занимает третье место с 2 222 объектами (10,1%). На противоположном полюсе находятся классы «Person» (человек) - 277 объектов (1,3%) и «Ladder» (лестница) - 202 объекта (0,9%). Разница между самым многочисленным классом («Hardhat») и самым малочисленным («Ladder») составляет почти 44 раза, что является серьезным дисбалансом.

Важной особенностью датасета является наличие парных классов: «Hardhat» / «NO-Hardhat», «Gloves» / «NO-Gloves», «Goggles» / «NO-Goggles», «Mask» / «NO-Mask», «Safety Vest» / «NO-Safety Vest». Такая структура позволяет решать задачу не только детекции СИЗ, но и выявления нарушений - ситуаций, когда работник находится на объекте без обязательного средства защиты.

Распределение количества объектов на одно изображение (центральная диаграмма рис. 21) показывает, что наиболее часто встречаются изображения с 1 и 2 объектами (около 50-80 изображений для каждого значения). Количество изображений с 3, 4, 5 объектами постепенно убывает. Изображения с 8 объектами и более являются редкими (единичные случаи). Такое распределение характерно для реальных сцен видеонаблюдения, где в кадре обычно находится небольшое количество людей и предметов.

Правая диаграмма (рис. 21) показывает, что подавляющее большинство изображений (97,6%) содержат аннотированные объекты, что свидетельствует о хорошей полноте разметки. Лишь 2,4% изображений не содержат объектов. Эти изображения могут выполнять роль «отрицательных примеров» для обучения модели (ситуации, когда искомым объектов в кадре нет).

3.3.2. Примеры типичных изображений с разметкой

На рис. 22 представлены примеры типичных изображений из набора данных с нанесёнными bounding boxes, демонстрирующие разнообразие сцен, ракурсов и условий освещения.




Рисунок 22 - Примеры изображений с аннотациями (bounding boxes)

Каждое изображение на рис. 22 сопровождается цветными bounding boxes, которые ограничивают обнаруженные объекты СИЗ или нарушения. Анализ примеров позволяет сделать следующие выводы.

Изображения охватывают различные производственные условия: складские и упаковочные помещения, зоны с техническим оборудованием, а также участки, где запечатлены работающие сотрудники. Такое разнообразие фонов положительно сказывается на способности модели к обобщению и позволяет обучать её на данных, приближенных к реальным условиям эксплуатации.

В выборке присутствуют изображения, снятые под разными углами и с разной дистанции. На ряде кадров люди находятся на среднем плане, занимая умеренную часть кадра, что характерно для большинства систем видеонаблюдения. На других изображениях объекты расположены крупным планом, что позволяет детально рассмотреть используемые средства защиты. Такое разнообразие масштабов является важной характеристикой датасета, так как модель учится детектировать СИЗ на разных расстояниях от камеры.

На всех представленных примерах видны bounding boxes, корректно ограничивающие объекты: каски на головах людей (прямоугольники зелёного цвета вокруг верхней части тела и головы), защитные очки (более мелкие прямоугольники в области лица). Визуально разметка выглядит качественной: прямоугольники плотно прилегают к контурам объектов, не выходят за их границы и не являются излишне крупными. Отсутствуют явные ошибки, такие как неполные боксы или захват лишних областей фона.

На примерах видны объекты различных классов: каски («Hardhat»), защитные очки («Goggles»), средства защиты органов дыхания («Mask»). Важно отметить, что на некоторых изображениях присутствуют сотрудники, использующие одновременно несколько средств защиты (каска + очки), что соответствует реальной практике на промышленных объектах, где требования к безопасности часто являются комплексными. На отдельных кадрах можно предположить наличие объектов класса нарушений (отсутствие обязательных СИЗ), что подтверждает возможность решения задачи контроля соблюдения правил безопасности.

Все представленные примеры имеют чёткое, неразмытое изображение с достаточным уровнем детализации для распознавания мелких объектов (например, защитных очков на лице человека). Освещение варьируется от

яркого дневного до умеренного искусственного, что обеспечивает разнообразие условий и повышает робастность будущей модели.

3.3.3. Оценка качества изображений

Анализ проведён на основе выборки изображений из набора данных. Результаты анализа представлены в таблице 10.

Таблица 10 - Статистика размеров изображений

Параметр	Ширина, пиксели	Высота, пиксели
Минимальное значение	640	640
Максимальное значение	640	640
Среднее значение	640	640

Все изображения в датасете имеют стандартизированное разрешение 640×640 пикселей, что является важным преимуществом. Во-первых, это позволяет уверенно различать объекты СИЗ, включая мелкие детали (очки, перчатки). Во-вторых, единый размер упрощает этап предварительной обработки: не требуется масштабирование или обрезка изображений перед подачей в модель. Формат изображений - JPEG, что соответствует требованиям инструкции и обеспечивает приемлемое качество без сильных артефактов сжатия. Изображения с низким разрешением, размытые или нечитаемые в наборе отсутствуют.

3.3.4. Анализ аннотаций (bounding boxes)

Для оценки качества разметки были проанализированы характеристики bounding boxes: их площади (нормализованные) и соотношения сторон. На рис. 23 представлены гистограммы распределения этих характеристик.




Рисунок 23 - распределение площадей (слева) и соотношений сторон (справа) bounding boxes

Средняя площадь bounding box составляет 0,0425 (в нормализованных координатах, где 1.0 соответствует всему изображению). Распределение имеет выраженную правостороннюю асимметрию: подавляющее большинство bounding boxes имеют площадь в диапазоне 0,01-0,08, что соответствует объектам, занимающим относительно небольшую часть изображения (типичная ситуация для видеонаблюдения, где человек в кадре занимает 5-15% площади). Редкие box'ы с площадью более 0,3 соответствуют ситуациям, когда объект (например, дорожный конус или человек) находится на переднем плане и занимает большую часть кадра. Наличие объектов разного масштаба - положительная характеристика датасета, так как модель учится детектировать СИЗ на разных расстояниях от камеры.

Среднее соотношение сторон (width/height) составляет 0,78. Это значение меньше 1, что означает, что в среднем bounding boxes имеют высоту, превышающую ширину. Такое соотношение характерно для вертикально ориентированных объектов: стоящего человека, строительной каски, дорожного конуса. Пик распределения приходится на диапазон 0,6-0,9, что подтверждает типичную «вертикальную» форму объектов СИЗ. Объекты с соотношением сторон более 1,5 (горизонтально вытянутые) встречаются редко. Узкое и унимодальное распределение свидетельствует об

однородности разметки - аннотаторы придерживались единых правил при выделении объектов.

3.3.5. Оценка качества разметки

Обобщённая оценка качества разметки по ключевым критериям представлена в таблице 11.

Таблица 11 - Оценка качества разметки набора данных

Критерий	Оценка	Комментарий
Формат аннотаций	Хорошо	YOLO (class x_center y_center width height) - соответствует задаче детекции
Полнота разметки	Хорошо	97,6% изображений имеют аннотации; все объекты в кадре, предположительно, размечены
Точность bounding boxes	Хорошо	Прямоугольники плотно прилегают к объектам; однородное распределение площадей и соотношений сторон
Баланс классов	Плохо	Сильный дисбаланс: класс «Hardhat» (40,5%) доминирует над «Ladder» (0,9%)
Наличие пустых аннотаций	Хорошо	2,4% изображений не содержат объектов (допустимо для «отрицательных» примеров)
Соответствие схеме меток	Хорошо	Все классы имеют единые названия, отсутствуют противоречия

В целом, качество аннотаций можно оценить как хорошее. Все объекты размечены в едином формате YOLO, что является индустриальным стандартом. Bounding boxes, судя по визуальной оценке (рис. 22), аккуратно обводят объекты. Отсутствуют систематические ошибки, такие как неполные боксы или пропуски объектов.

Основной проблемой является сильный дисбаланс классов. Модель, обученная на таких данных, будет хорошо детектировать каски (класс «Hardhat»), но может иметь низкую точность на редких классах («Ladder», «Person», «NO-Safety Vest»). Рекомендуется на этапе предварительной обработки применить методы балансировки: oversampling (увеличение числа примеров редких классов за счет дублирования или аугментации) или использование взвешенных функций потерь (class weights).

ЗАКЛЮЧЕНИЕ

В рамках курсового проекта выполнен поиск и первичный анализ наборов данных разных типов по различным областям применения. В ходе выполнения работы были получены следующие основные результаты:

1) подготовлено для каждого типа данных (табличные данные, временные ряды, изображения, тексты) краткое описание выбранной задачи, решение которой связано с применением технологий искусственного интеллекта;

2) подобран и обоснован выбор для каждого типа данных набор данных из авторитетных открытых источников, необходимый для обучения ИИ-модели, решающей соответствующую выбранную задачу;

3) реализован комплекс программ на языке Python, каждая из которых для заданного типа данных выполняет основные функции первичного анализа;

4) сформулированы выводы по каждому этапу анализа, а также итоговое заключение о качестве данных и их пригодности для решения поставленной задачи;

5) размещен исходный код в репозитории системы контроля версий Git [1].

ЛИТЕРАТУРА

1. Dorma, A. A. CourseWork / A. A. Dorma. - GitHub, 2026. - 15 Apr. - URL: <https://github.com/ArseniyDorma/CourseWork> (дата обращения: 15.04.2026). - Режим доступа: свободный. - Текст: электронный.
2. Yentür, M. text-to-sql / M. Yentür // Kaggle. - 2024. - 11 June. - URL: <https://www.kaggle.com/datasets/meryentr/text-to-sql/data> (дата обращения: 15.04.2026). - Режим доступа: свободный (требуется регистрация). - Текст: электронный.
3. IMS Bearing Dataset. - URL: <https://data.nasa.gov/dataset/ims-bearings/resource/7adad32f-5984-4a38-b1e3-e0dd2e462dc8> (дата обращения: 30.04.2026). - Режим доступа: свободный.
4. Raval, S. PPE Dataset YOLOv8 / S. Raval // Kaggle. - 2024. - URL: <https://www.kaggle.com/datasets/shlokraval/ppe-dataset-yolov8> (дата обращения: 16.05.2026). - Режим доступа: свободный (требуется регистрация). - Текст: электронный.